

武汉大学学报(信息科学版)
Geomatics and Information Science of Wuhan University
ISSN 1671-8860,CN 42-1676/TN

《武汉大学学报(信息科学版)》网络首发论文

题目：大语言模型智能体驱动的出行日志生成技术
作者：黄菲，肖智雄，李旭川，李国隆，乐阳
DOI：10.13203/j.whugis20250277
网络首发日期：2026-02-14
引用格式：黄菲，肖智雄，李旭川，李国隆，乐阳．大语言模型智能体驱动的出行日志生成技术[J/OL]．武汉大学学报(信息科学版).
https://doi.org/10.13203/j.whugis20250277

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-02-14 14:45:50　网络首发地址：https://link.cnki.net/urlid/42.1676.TN.20260214.1352.001

DOI: 10.13203/j.whugis20250277
引用格式:
黄菲, 肖智雄, 李旭川, 等. 大语言模型智能体驱动的出行日志生成技术[J]. 武汉大学学报（信息科学版）, 2026, DOI: 10.13203/j.whugis20250277（HUANG Fei, XIAO Zhixiong, LI Xuchuan, et al. Travel Diary Generation Based on Large Language Model Agent [J]. *Geomatics and Information Science of Wuhan University*, 2026, DOI: 10.13203/j.whugis20250277）

大语言模型智能体驱动的出行日志生成技术

黄菲[1]　肖智雄[1]　李旭川[1]　李国隆[1]　乐阳[2]
1 深圳大学建筑与城市规划学院城市空间信息工程系，广东 深圳，518060
2 香港科技大学（广州）社会枢纽城市治理与设计学域，广东 广州，511453

摘 要：人类出行数据是洞察人地交互规律、解构城市复杂系统的基础。但真实出行数据获取难度大，且受限于隐私保护，已成为城市研究和地理过程建模等领域的关键数据瓶颈。大语言模型智能体（Large Language Model Agent, LLM-Agent）已在人类认知决策模拟方面崭露头角，为城市出行数据合成提供了新思路。但面临的核心挑战在于：如何将 LLM 从通用推理器，变为可准确建模异质性出行行为与城市环境深层互动规律的模拟器。为此，本研究提出一个基于属性-行为自洽与空间吸引力双重约束的出行日志生成框架（Human **Mobi**lity Generation **A**gent, MobiA），通过注入结构化的出行关联知识，驱动 Agent 生成兼具个性化与地理真实性的时空活动。MobiA 从大规模真实数据中挖掘社会属性与时空行为间的异质性规律，构建出行模式知识库。并借助检索增强生成技术将其动态注入 Agent 的层级决策过程，为个性化行为提供知识约束。其次，通过构建地块吸引力指标，量化空间语义，将抽象出行意图与真实城市环境精准匹配，完成地理空间约束。本研究基于 20 万出行调查数据进行训练，验证结果表明，MobiA 合成数据在复现个性化出行链的真实性与宏观人流分布的地理相似性上，均与观测数据高度吻合。该框架为探索 LLM-Agent 模拟复杂的人-地交互应用提供了可行的技术路径，其合成结果可为以人为本的智慧城市建设与决策提供关键数据支撑。
关键词：出行数据生成；智能体；生成式人工智能；移动轨迹；大语言模型

Travel Diary Generation Based on Large Language Model Agent

HUANG Fei[1]　*XIAO Zhixiong*[1]　*LI Xuchuan*[1]　*LI Guolong*[1]　*YUE Yang*[2]
1 Department of Urban Informatics, School of Architecture and Urban Planning, Shenzhen University, Shenzhen 518060, China
2 Thrust of Urban Governance and Design, Hong Kong University of Science and Technology (Guangzhou) Guangzhou 511453, China

Objectives Human mobility diaries, represented as sequences of time–place–purpose events, provide a fundamental basis for understanding human–environment interactions and the dynamics of urban systems. Yet high-quality real-world mobility data are increasingly hard to obtain due to privacy constraints, collection costs, and sampling biases, creating a persistent bottleneck for urban studies and geographic process modeling. Large language model agents offer a new direction by simulating human-like decision making, but what does it take for a diary to be mobility-valid, not merely

基金项目：粤港澳高校“1+1+1”联合研究专项（C/G_2025_028）
第一作者：黄菲，博士生，主要从事地理空间智能研究。Huangfei2022@email.szu.edu.cn
通信作者：乐阳，博士，教授，从事城市大数据、地理人工智能和社会可持续发展的交叉研究。yangyue@hkust-gz.edu.cn

language-plausible? Specifically, how can an LLM generate activity chains that remain consistent with individual attributes and ground abstract intentions in locations that are both semantically appropriate and accessible? **Methods** To produce synthetic diaries that are both behaviorally plausible and spatially realistic for downstream urban analysis and policy evaluation, we propose LLM-Driven Human Mobility Generation Agent (MobiA), a travel-diary generation framework built on a dual anchoring mechanism i.e., Sociodemographic Grounding and Spatial Attractiveness. First, to enforce attribute–behavior self-consistency, MobiA mines fine-grained mobility groups from large-scale travel surveys and distills pattern–motivation knowledge into a retrievable knowledge base, which is further validated and updated through contextual evaluation. Second, to ensure geographically valid grounding, the city is represented as road-enclosed parcels, and an attractiveness model maps travel intentions to feasible parcels based on semantic supply and accessibility. Conditioned on an agent profile, MobiA performs hierarchical schedule planning and event refinement under retrieved constraints, and then grounds each event to parcel locations via the learned attractiveness scores. **Results** MobiA is trained and validated using a large-scale Shenzhen WeChat travel survey dataset, which contains 22,228 users, 199,380 trips, and 32,727 locations after preprocessing. (1) We conduct two controlled cohort experiments to test whether MobiA produces attribute-grounded personalization. For women aged 30–35 on weekday mornings, MobiA shifts destinations from a commute-only business-district cluster to increased school-area activity, consistent with family–work routines. For male car owners aged 30–35 with middle-to-high income on weekends, MobiA shifts trips from near-home leisure to longer-distance destinations such as parks, museums, seaside areas, and major shopping centers, demonstrating fine-grained demographic heterogeneity in generated diaries. (2) City-scale realism. We simulate ~50,000 residents and compare 24-hour parcel-level dynamic population against Baidu Maps. As shown in Fig.3, the cosine similarity exceeds 0.8 in >90% of parcels (weekdays and weekends), and >70% of parcels achieve density-fitting >0.5, indicating strong alignment of spatiotemporal population patterns at the parcel scale. **Conclusions** MobiA generates high-quality, controllable travel diaries with strong behavioral realism and geographic validity. Its dual grounding mechanism links sociodemographic attributes to daily routines and links urban semantics and accessibility to destination choices. We emphasize that individual mobility synthesis must respect both behavioral regularities and spatial feasibility to avoid plausible-but-floating diaries.

Key words: travel data generation; agent; generative artificial intelligence; trajectory; large language model

人类出行承载了连接居住、就业、公共服务和城市发展，对于理解复杂的人地关系、优化城市系统至关重要[1–4]。高质量的真实个体活动数据因隐私保护和采集限制而难以获得，即制约了人地关系与城市行为的研究，也限制了相关地理空间模型的构建与应用。高质量的合成出行数据因此成为突破这一数据瓶颈的关键途径[5–7]。当前，个体轨迹生成主要有两条技术路径：1）基于预设规则的机理模型，2）基于数据驱动的机器学习模型。机理模型的代表包括随机游走[8–10]、探索与偏好返回[11–13]等，通过构建规则来模拟人类移动的宏观统计规律。这类方法虽具可解释性，但整体对个体活动进行简化，较难捕捉复杂意图与偏好驱动的异质性与随机性。基于生成式的深度学习模型，如变分自编码器[14,15]、对抗神经网络[16–18]、扩散模型[19–21]等，能够从大规模轨迹数据中自动学习潜在规律，捕捉复杂的出行时空依赖关系[22,23]，但其“黑箱”特性使其难以解释和迁移，且高度依赖大规模训练数据。

大语言模型（LLM）已具备较强的逻辑与推理能力，由其驱动的智能体（Agent）开始以“角色扮演”的形式在人类行为模拟和决策制定的相关研究中显示出独特的优势与潜力[24–28]。这也为合成人类出行数据开辟了从统计拟合转向对人类认知决策模拟的新范式。现有的研究基于 LLM 的常识推理能力，从用户属性和历史轨迹总结移动规律，Agent 因此能够生成符合通识逻辑的出行目的与活动序列[29–32]；但将这一潜力转化为精确、可靠的城市出行模拟，LLM-Agent 面临着连接认知推理与地理现实的两个关键技术挑战：

（1）个性化出行特征的融合与可控性。当 LLM 过于依赖内部强大且泛化的通用知识，会阻碍其从真实数据中提炼具有地域和人群特异性的隐性出行模式[33–35]，生成结果往往陷入“平均人”[36]的刻板印象，且其过程存在幻觉风险，缺乏可控的、逻辑自洽的行为规则进行引导与约束[37]。

（2）地理语义锚定的任意性。LLM 能够推理出抽象的出行意图（如“社交聚餐”），但普遍缺乏将此意图与复杂的、异质化的城市物理空间[38–40]进行精确匹配和约束的机制。这导致合成的决策链虽在逻辑上合理，但在空间上却是悬浮、失准的。

针对上述问题，本文提出基于属性-行为自洽性与空间吸引力原则双重约束下的人类城市出行模拟框架（Human **Mobi**lity Generation **A**gent, MobiA）。借助检索增强生成（Retrieval-Augmented Generation, RAG）[37] 技术，本研究将从大规模真实出行中建模的具有人群异质性的隐性出行模式动态注入 Agent 的决策过程，解决合成出行行为的常识性有余、个性化不足的问题。其次，构建城市地块尺度的空间出行吸引力模型；通过可量化的空间选择函数，将抽象的出行意图转化为在综合考虑城市功能、兴趣点（POI）分布及可达性等多种建成环境变量后的空间位置选择。MobiA 构建出链接认知决策到空间映射的完整路径，能够生成兼具行为自洽性、经验真实性与地理合理性的细粒度个体出行日志，即包含出行目的、类型、起止时间和位置信息的时空序列。在隐私保护日益严格、真实出行数据获取日趋困难的背景下，MobiA 合成的出行日志可以缓解数据匮乏带来的研究限制，也为理解不同社会群体（包括弱势群体与特定人群）的差异化出行需求、促进以人为本的智慧城市建设提供了新的可能性。

1 方法

MobiA 旨在模拟一个“社会人”如何基于其个性化属性进行移动认知决策，并符合一个“空间人”在复杂的城市环境中完成地理落地的完整过程。MobiA 的框架设计立足于解决两个问题：（1）如何确保 LLM 准确建模人类社会属性与出行行为的深层关联，并合成连贯的、具有异质性的出行日程？（2）如何确保合成数据符合真实城市的空间布局和配置？

如图 1 所示，MobiA 由三个核心模块组成：**1.** 自洽性[41]（self-consistency）的出行模式提取与知识库构建：以个人属性与行为的自洽性为约束进行多维度重建任务，从真实数据中挖掘细粒度人群的出行规律与动机，并形成可供智能体检索的知识库；**2.** 基于动机推理的具体日程生成：智能体依据其个性化属性，并结合从知识库中检索到的模式，通过层次性推理生成贴合个人特征的出行日程表；**3.** 出行日程的空间映射：构建地块吸引力模型，将抽象的日程事件精准映射到具体的城市地块上，最终

生成完整的时空轨迹。

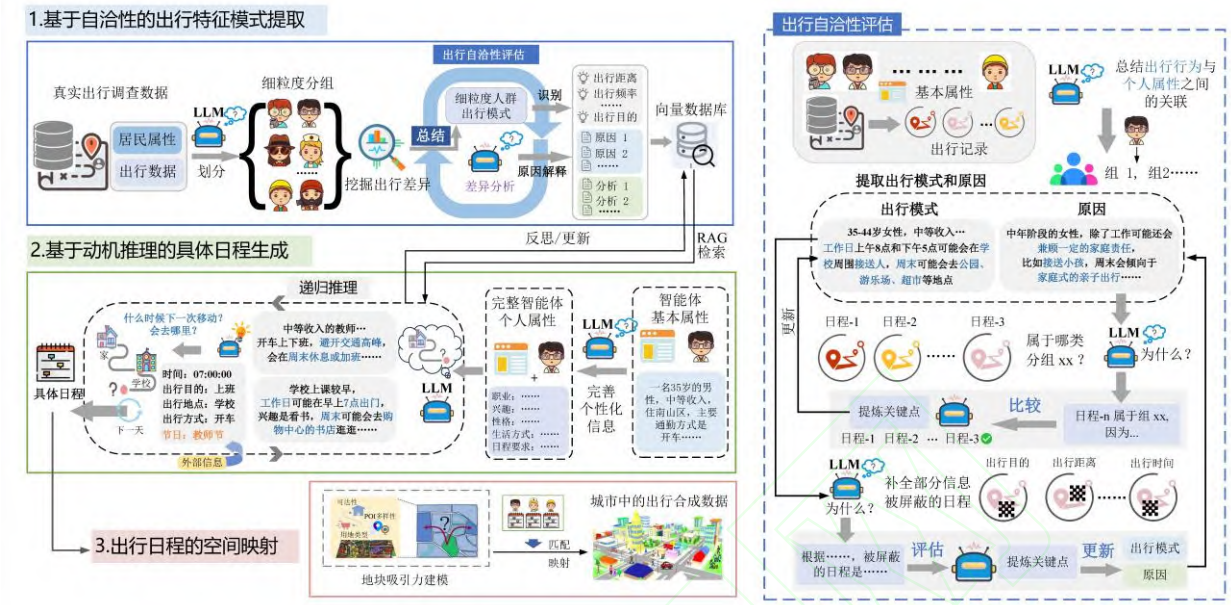


图 1 MobiA 出行日志生成流程图

Fig. 1 Workflow of MobiA in Travel Diary Generation

1.1 基于自洽性的出行特征模式提取与知识库构建

MobiA 基于情境分析和重建任务来建模人类移动的一般模式和个人差异。宏观层面，一般模式包括通勤需求、特定时空框架内的受限出行距离和频率。微观层面的比较旨在解释如性别、年龄和收入等个人属性如何影响出行目的、方式和时间等移动行为。为避免仅依赖表层统计特征导致不同子群体的行为差异被弱化，MobiA 在模式归纳的同时进一步识别支撑这些模式的潜在动因，以作为 LLM 推理时的重要上下文，使模型能够更准确地捕捉不同人群在行为逻辑上的真实差异。MobiA 在决策模拟中采用自上而下的层级结构，包括个体属性层、日程框架层和活动级决策层。不同层级各自携带相应的属性，例如个体层的年龄与收入等级，日程层的时间预算与约束事件，活动层的具体出行目的与地点。模型通过多轮自洽评估，从不同层次的属性差异中解释用户的行为差异，并对日程结构与活动选择的合成进行调整更新。

细粒度人群的出行模式提取：给定户集合$U = \{u_1, u_2, \dots, u_N\}$及其对应的人口统计属性$A_{stat}$进行多阶段聚类分析。基于可解释性机器学习技术（SHAP）分析各属性维度a_j对出行行为分异的贡献度$I(a_j)$，以得到具有高度内部相似性的细粒度子群体$\{G_1, G_2, \dots, G_K\} = Clsuter(U, A_{stat}, K)$。在此基础上，利用 LLM 的语义理解和推理能力，从子群体G_k的原始出行记录D_k中，归纳、挖掘子群体G_k的出行模式S_K和潜在动因R_K，以关联行为模式、用户属性与深层动机之间的逻辑链条：

$$(S_k, R_k) = InferPattern_{LLM}(D_k, G_k, I(A)) \tag{1}$$

出行知识库构建与验证更新：出行模式-动因对(S_k, R_k)被转化为向量单元v，用以构建动态出行知识库$\mathcal{KB} = \{v(S_k, R_k)\}_{k=1}^{K}$。智能体$i$产生状态查询$q_i$,RAG 检索出最相关的知识单元$(S_k, R_k) = Match_{RAG}(q_i, \mathcal{KB})$,作为其情景决策的支持。为确保$\mathcal{KB}$的可泛化性，本文引入出行一致性评估机制，包括情境化分类验证与信息补全决策模拟两部分。情境化任务通过分类准确率$f_{cls}(\cdot)$验证模式有效性，即以提取的出行模式为大模型先验知识，判断一组去标识出行轨迹$T_{test} = \{tr_1, \dots, tr_m\}$的群体归属$G(tr_j)$：

$$\hat{G}(tr_j) = f_{cls}(tr_j | \{S_k\}_{k=1}^{K}, LLM_{prior}) \tag{2}$$

$$Accuracy = \frac{1}{m}\sum_{j=1}^{m} \mathbb{I}\left(\hat{G}(tr_j) = G(tr_j)\right) \tag{3}$$

其中，LLM_{prior}为用于模式抽取的模型，$\mathbb{I}(\cdot)$为指示函数，当条件成立时为 1，否则为 0；当$\mathbb{I}(\cdot) = 0$时，引入评估模型LLM_{eval}，分析错误匹配的群体间轨迹和出行模式的差异性，作为后续$\mathcal{KB}$更新的依据：

$$E_C = \Delta_{diff} = LLM_{eval}\left(tr_j, S_{\hat{G}(tr_j)}, S_{G(tr_j)}\right) \tag{4}$$

信息补全与决策模拟：随机选取轨迹$tr_j \in D_k$，对tr_j中的关键信息I_{masked}（活动或目的地）进行掩盖（mask），得到$tr_{j,masked}$。要求LLM_{prior}依据其习得的{S_k}对$tr_{j,masked}$进行补全：

$$\hat{I}_{pre} = f_{pre}\left(tr_{j,masked} \middle| S_k, LLM_{prior}\right) \tag{5}$$

$$E_P = LLM_{eval}\left(M_{match}\left(\hat{I}_{pre}, I_{masked}\right)\right) \tag{6}$$

此过程有助于优化人群属性$A(G_k)$ 与出行模式S_k之间的映射关系，确保提取的出行模式兼具可描述性和可预测性。在两类情景化任务中，LLM_{eval}负责识别和分析影响决策的关键差异点（即误差来源），并在随后的更新步骤中将其用于调整模式与动因，以提升知识库的完备性和区分度：

$$\mathcal{D}^t = LLM_{eval}(E_C^t, E_P^t, \mathcal{KB}^t) \tag{7}$$

其中，$\mathcal{D}^t$为针对特定(S_k, R_k)给出的优化建议，$\mathcal{KB}^{t+1} = \mathcal{O}_{refine}\{\mathcal{KB}^t, \mathcal{D}^t\}$。

1.2 基于动机推理的具体日程生成

在 1.1 构建的出行模式知识库$\mathcal{KB}$的基础上，本节通过动机推理的层级化日程生成方式，模拟人类在真实约束下进行出行决策与日程规划的复杂认知过程。

给定初始 Agent 的属性为A_{stat_i}（如年龄、性别），大语言模型$InferAtt_{LLM}(\cdot)$在此基础上进行差异化增强，采用动态温度参数τ调控策略，补全其职业、性格、生活方式偏好以及潜在的日程约束$\mathcal{K}_{stat_i}$，形成多样化的个性化属性集$A_{tt_i}(A_{stat_i}, \mathcal{K}_{stat_i})$。结合从$\mathcal{KB}$中动态检索到的相关出行模式与出行动机，将其作为核心约束与启发式信息，指导后续的行程规划。

$$A_{tt_i} = InferAtt_{LLM}\left(A_{stat_i}, \tau\right) \tag{8}$$

$$(S_i^*, R_i^*) = SelectPattern\left(A_{tt_i}, \mathcal{KB}\right) \tag{9}$$

日程生成采用自顶向下的层级化策略，结合思维链（CoT）技术进行多步推理，完成从日度行程的宏观规划到时刻级（时/分钟）活动的递归细化。即，LLM 基于A_{tt_i}和选定的(S_i^*, R_i^*)以及外部环境因素E_{xt}（如天气、节假日），通过 CoT 推理生成当日的核心出行动机序列及大致的行程框架：

$$P_{daily_i} = LLM_{CoT}^{daily}\left(A_{tt_i}, S_i^*, R_i^*, E_{xt}\right) \tag{10}$$

在递归生成阶段，智能体综合考虑整体行程计划P_{daily_i}和已执行的出行行为$S_t = \{H_0, \ldots, H_{t-1}\}$，生成下一个时间步 t 的具体日程，最终按照{时间，地点，事件}三元组的格式输出，$H_t = (t, loc_t, event_t)$:

$$H_t = LLM_{CoT}^{daily}\left(A_{tt_i}, \mathcal{S}_i^*, \mathcal{R}_i^*, E_{xt}\right) \tag{11}$$

此递归过程确保了日程在宏观逻辑与微观行为间的连贯性与合理性，模拟了人类从目标到具体行动的决策路径。

1.3 顾及地块吸引力的出行日程空间映射

路网作为连接城市空间和反映城市结构的基础框架，由其围合而成的地块能够较好地表达城市的功能格局，空间连续性与可达性特征，适合作为活动地点选择的基本空间载体。为刻画出行目的在城市空间中的吸引差异，本文采用地块级尺度构建空间吸引力模型。结合地块用地类型数据和 POI 数据构建地块级吸引力模型，量化每个地块对于出行智能体特定目的的吸引程度，进而实现抽象日程地点在具体地块上的映射，具体流程如图 2 所示。

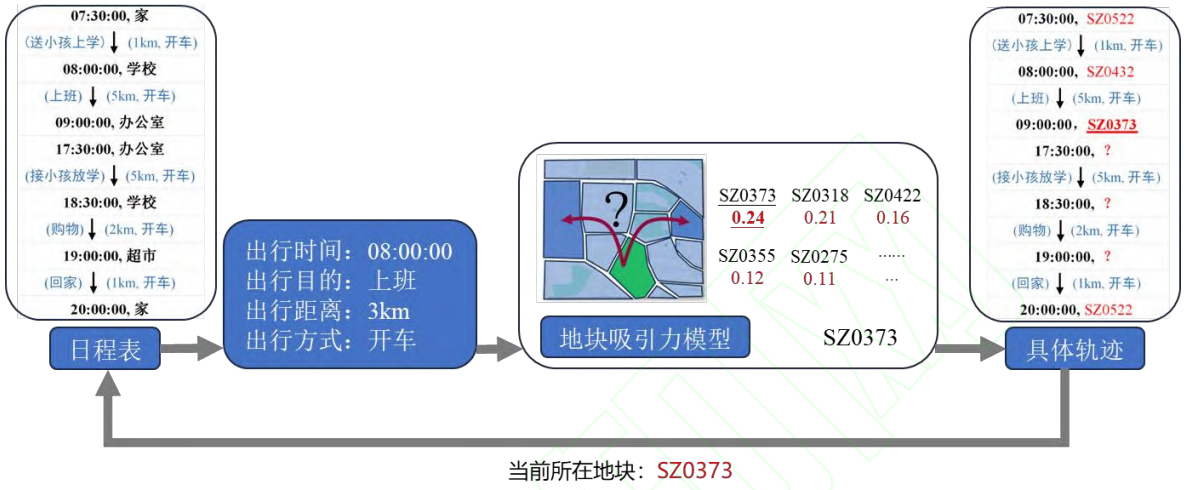


图 2 基于地块吸引力将 Agent 生成的出行计划匹配至城市地块

Fig. 2 Match Movements to Parcels in the City by Considering the Attractiveness of Parcels

地块总吸引力计算选取 POI 类型分布及其数量密度、用地类型、出行距离作为解释变量，计算公式如下：

$$T(D,P) = F(w_k,(D,P),s_k), \qquad k = \{dens, divs, dist\} \tag{12}$$

其中D为时间标识（工作日或周末），P为出行目的，w_i为指标权重，s_k为吸引力指标，包含 POI 密度得分s_{dens}，POI 多样性得分s_{divs}以及距离得分s_{dist}，计算方式如下：

① 出行目的相关 POI 密度得分：POI 的重要程度可类比为语料库中词语的重要性。但以地块为分析单元时，多数 POI 类别在空间上的普遍存在性会导致 TF-IDF 的逆文档频率指标失效，无法衡量其在特定地块的真实权重[42]。因此，本文在 IDF 的计算时，采用相关用地类型在周围地块中出现频率来达到相同目的。假设与当前出行目的P相关的 POI 类别有m类，与当前出行目的P相关的用地类型集合为A，则地块i的s_1计算公式如下：

$$S_{dens}^{i} = \frac{\sum_{k=1}^{m} POI_{Count_i}^{k}}{\Omega(A_i)} \times log\left(\frac{N}{n+1}\right) \tag{13}$$

其中$POI_{Count_i}^{k}$为地块i中第k类 POI 的数量，$\Omega(A_i)$为地块i的面积，N为所有待选地块数,n为包含用地类型集合A的地块数。

② POI 多样性得分：在出行地点的选择中，人们往往倾向于选择能够满足多重需求的目的地，高 POI 多样性的地块能够提供更多的选择机会和组合可能，从而增加其作为出行目的地的吸引力。POI 多样性得分可以通过统计该地块内所含 POI 的种类数计算得到：

$$S_{divs}^{i} = \frac{Type_i}{max(Type)} \tag{14}$$

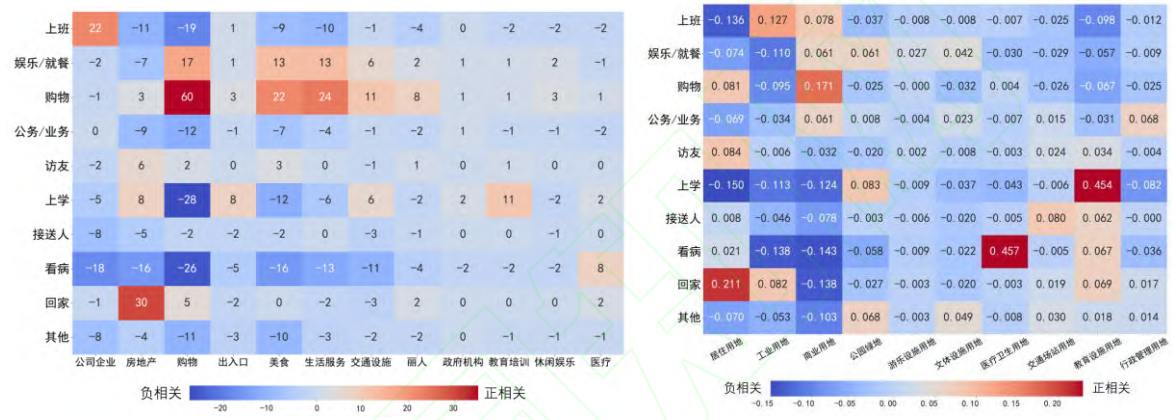
其中$Type_i$为地块i中 POI 的种类数，$max(Type)$为所有地块中 POI 种类数的最大值。

③ 距离得分：根据引力模型和空间交互理论，两个地点之间的相互作用强度与它们之间的距离成反比。故通过子指标的距离衰减函数可有效反映空间可达性对地块吸引力的影响：

$$S_{dist}^{i} = e^{-\beta \times distance_i} \tag{15}$$

其中$distance_i$为地块i距离当前地块的距离，β为衰减速率超参数，取值在 0.1 到 0.5 之间。

基于提出的地块吸引力指标构建方法，需先明确地块用地类型、POI 类别与出行目的之间的关系。在量化关联机制时，以真实调查数据中居民实际访问的地块为样本，分别提取地块的用地类型占比与各类 POI 的密度等空间特征。对于每一类出行目的 p，构造两组特征样本：（1）目的为p的出行所访问地块的特征值；（2）非p的出行所访问地块的对应特征值。随后使用 Mann–Whitney U 检验比较两组样本在该特征上的秩差，以判定其显著性。在此基础上，以两组样本的中位数差作为效应量指标，以规避均值对极端值的敏感性问题，准确反映实际影响程度。根据计算结果生成的效应量矩阵如图 3 所示。



(a) POI 类别-出行目的效应量矩阵热力图　　(b) 用地类型-出行目的效应量矩阵热力图

图 3 POI 类别、土地利用类型和出行目的之间的效应大小矩阵热图

Fig. 3 Heatmap of Effect Size Matrix between POI Categories, Land-Use Types, and Travel Purposes

本研究采用基于候选集排序的 Softmax 回归模型[43]建模地块吸引力概率函数的指标权重。设某次出行目的的候选地块集合为 $C = \{c_1, c_2, \dots, c_n\}$，每个地块$c_i$的特征向量为$x_i = [s_{dens}^{i}, s_{divs}^{i}, s_{dist}^{i}]$，通过 Softmax 函数计算选择地块$c_i$的概率为：

$$P(c_i|C) = \frac{exp(y_i)}{\sum_{c_j \in C} exp(y_j)}, \quad y_i = \boldsymbol{w}^T \boldsymbol{x}_i + b \tag{16}$$

模型目标为最大化真实转移地块的似然概率，定义交叉熵损失函数：

$$\mathcal{L} = -\sum_{k=1}^{K} log\, P(c_k^*|C_k) \tag{17}$$

其中K为训练集转移事件总数，参数$\boldsymbol{w}, b$通过 Adam 优化器[44]迭代更新。

在模型性能评估阶段，除交叉熵损失分析外，还采用 Top-1 准确率和平均倒数排名 MRR 两类指标，分别从绝对匹配精度和概率排序可靠性两个维度量化模型效果，确保学习所得权重既能精准识别最优地块，又能合理反映候选集内竞争地块间的相对吸引力差异。考虑到城市居民工作日与周末时空行为模式存在差异，故分别对工作日与周末的权重参数进行独立训练，最终生成的权重结果参数如表 1 所示。

表 1 地块吸引力指标权重学习结果

Table 1 Weights of Indicators in Parcels Attraction Modeling

出行目的	相关 POI 密度得分权重		POI 多样性权重		距离权重	
	工作日	**周末**	**工作日**	**周末**	**工作日**	**周末**
上班	0.51	0.43	0.11	0.19	0.38	0.38
娱乐/就餐	0.56	0.59	0.31	0.37	0.13	0.04
购物	0.53	0.63	0.27	0.31	0.20	0.06
公务/业务	-	-	0.13	0.15	0.36	0.29
访友	0.41	0.38	0.21	0.28	0.38	0.34
上学	0.59	0.57	0.11	0.14	0.30	0.29
接送人	-	-	0.12	0.14	0.37	0.36
看病	0.54	0.58	0.16	0.17	0.3	0.25
回家	-	-	-	-	-	-
其他	-	-	0.20	0.21	0.30	0.30

2 出行日志生成结果与分析

本文重点模拟城市特定区域内居民的出行行为，空间属性数据（POI，用地类型）和人口属性（人口规模与用户画像）作为输入，通过聚合个体轨迹形成宏观人流分布。从出行模式相似性、流动趋势一致性以及预测精度展开分析，以验证本方法在城市人流量预测下游任务中的有效性与应用潜力。

研究选取 2016 年 11 月至 2017 年 1 月期间深圳的微信出行调查数据作为大模型学习不同人群出行模式的训练数据集。该出行调查数据结合深圳市交通调查同步开展，经数据清洗与预处理后，得到 22228 名用户的 199380 条出行信息，涉及 32727 个出行地点。调查数据包含居民的出行地点、出发及到达时间、主要交通方式等信息。数据主要由用户基本信息表和出行信息表组成。用户基本信息表主要字段如表 2 所示，出行信息表主要字段如表 3 所示。

表 2 用户基本信息表主要字段

Table 2 Main Fields of Users

编号	字段名称	示例
1	用户 ID	llxqcy27
2	年龄	25
3	性别	女
4	职业	职员
5	收入状况	<=10 万
6	住房来源	集体宿舍
7	是否有车	否
8	主要出行方式	公共交通
9	居住区域	南山区
10	居住地址	XX 小区 XX 单元
11	公司或学校区域	南山区
12	公司或学校地址	XX 小区 XX 单元

表 3 出行信息表主要字段

Table 3 Main Fields of Travel Information

编号	字段名称	示例
1	出行目的	上班
2	出发时间	2016-11-16 06:27
3	出发地点	XX 小区 XX 单元
4	到达时间	2016-11-16 07:27
5	到达地点	XX 路 XX 号
6	出行方式	地铁

将处理后的数据空间分布如图 4 所示，调查覆盖范围基本涵盖了深圳市内人口密集、交通网络发达的主要区域，未被调查覆盖的区域大多为生态绿地，路网较少，人口密度较低。

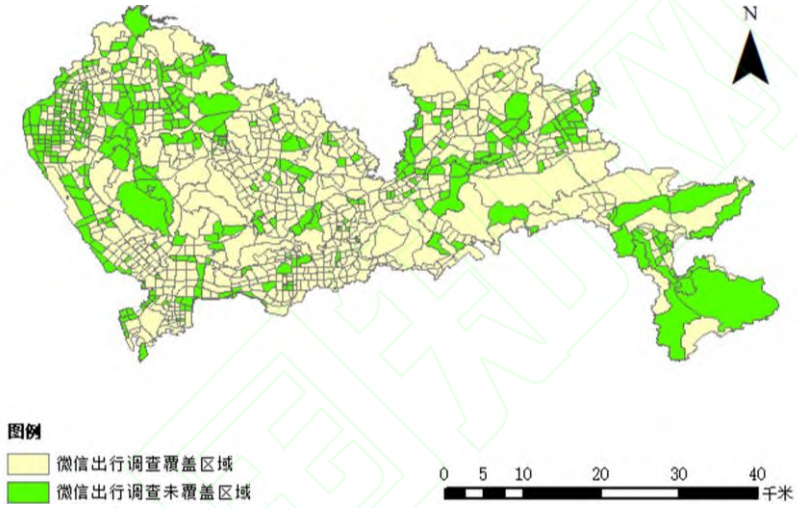


图 4 微信出行调查数据覆盖范围

Fig. 4 Travel Survey Data Coverage Scope in Space

实验采用的大语言模型为 DeepSeek R1 和 V3。实验显示，R1 模型在智能体总体规划任务中表现出色，能够高效实现任务的全局规划与统筹；V3 模型则聚焦于细分任务的执行，在具体任务的精细化处理方面展现出独特优势。

表 4 实验数据清单

Table 4 The List of Experimental data

使用数据	**数据来源**	**用途**
人口数量与画像数据	百度地图（2023）	智能体基本属性输入
用地类型数据	深圳市规划和自然资源局（2019）	地块基本属性输入
POI 数据	百度地图（2023）	地块基本属性输入
出行调查数据	微信公众号问卷调查（2017）	训练地块吸引力参数
24 小时人流量数据	百度地图（2023）	验证实验模型效果

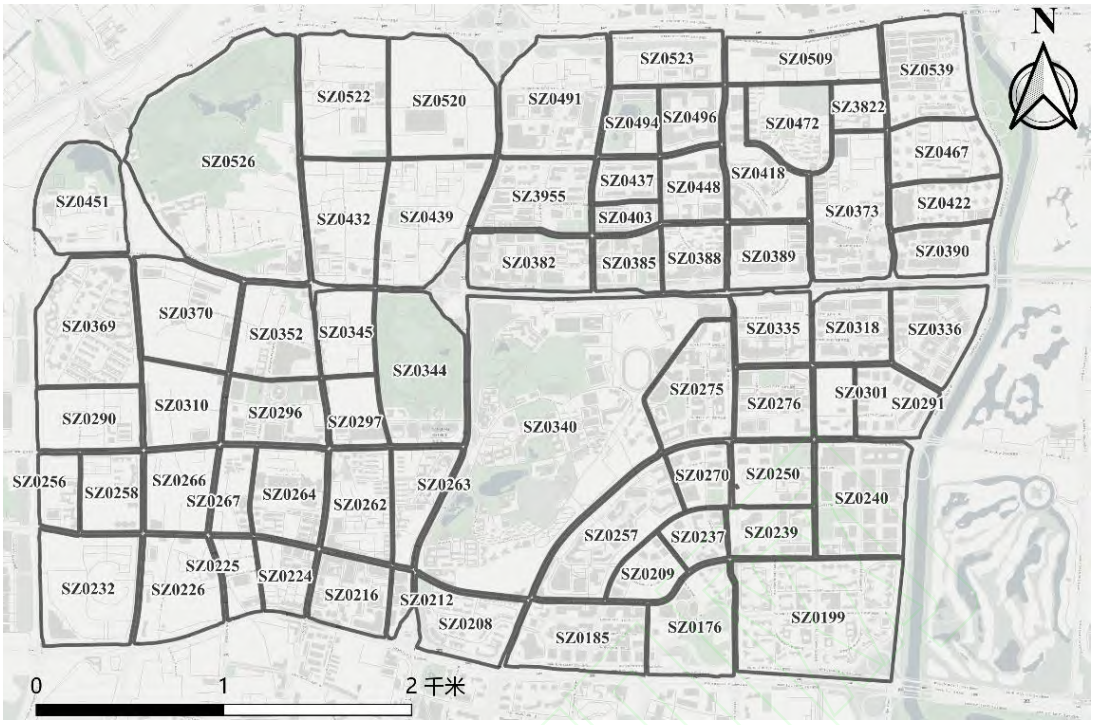


图 5 实验区域的地块划分与编号

Fig. 5 Parcels and Their Index in the Experimental area

如图 5 所示，本研究选取深圳市南山区一片约 5 km × 3 km 的区域，并基于 OpenStreetMap 的三级路网进行道路围合划分，共得到 68 个地块单元作为智能体活动空间。该区域位于南山区经济核心地带，集商业办公、居民生活、科研教育及休闲游憩等多类城市功能于一体，出行类型丰富、场景多样。三级路网能够较好地反映区域的主要空间结构，兼顾地块数量与空间分辨率，使该区域适合作为模型在复杂城市环境下进行出行逻辑推断与空间映射能力验证的实验场景。不同研究任务可根据需要调整路网层级，以灵活控制地块尺度。实验使用具体数据清单详见表 4。

2.1 提取出行模式的有效性与评估

本次模拟生成出行实验先针对出行模式的提取效果进行有效性评估，根据出行调查数据提取出的细分人群出行模式部分展示如表 5 所示。

表 5 细分人群出行模式表

Table 5 Mobility Patterns for Fine-Grained Segmented Groups

细分人群	出行特征
18 岁以下学生	1、 出行时间高度固定，早高峰集中在 7:00-8:00，晚高峰 16:00-17:30，寒暑假频率下降明显。 2、 小学阶段多由家长接送或搭乘校车，初高中逐渐转向步行/骑行或公共交通。 3、 晚上出行次数较少 ……
18-25 岁上班族	1、 通勤依赖公共交通居多，早高峰集中在 8:00-10:00，晚高峰集中在 17:30-19:00，19:00-22:00 仍有下班出行。

细分人群	出行特征
	2、 午休时段有短途外出（便利店、快餐店），夜间及周末偏好购物或娱乐地点。 3、 晚上出行比例较高，女性相较男性出行频率稍多。 4、 工作日和周末出行次数相差较大，早晚高峰出行周末比工作日下降明显。 ……
35-44 岁高收入人群	1、 有车人群占比相对平均水平较高。 2、 工作通勤时间相对提早，时间分布上较为不固定。 3、 周末出行频率降低，但单次时长增加，长距离出行偏多。 ……
35-44 岁女性	1、 出行频率明显高于平均水平。 2、 出行目的为接送人的占比偏高，地点集中在学校等区域，考虑家庭因素较多。 3、 周末出行目的多为公园、游乐场、超市等地点。 ……
55 岁以上人群	1、 出行频率相对较低，早上出行偏多，6:30-8:00 时段最为明显，晚上出行较少。 2、 工作日和周末出行频率相差不明显，远距离出行偏少。 ……

本文选取经典的基于深度学习的人类移动行为预测模型 DeepMove[45]作为对比基线，以移动距离（SD）、移动时间间隔（SI）、停留点个数（ST-LOC）以及日访问点（DailyLoc）作为为统计层面的评价指标，从时空维度对合成轨迹背后的行为特征进行验证。对比评估如表 6 所示，指标数值均为越小越好。其中 MobiA (w/o SC)代表移除“基于自洽性的出行模式提取机制”，Agent (w/o R)代表移除基于推理的具体日程规划策略。

表 6 基于统计指标的模型表现评估

Table 6 Performance Comparison on Statistical Evaluation

模型	SD↓	SI↓	ST-LOC↓	DailyLoc↓
DeepMove	0.5614	0.4462	0.5917	0.5490
MobiA (w/o *SC*)	0.0847	0.1360	0.1304	0.1251
MobiA (w/o *R*)	0.0811	0.1190	0.1172	0.1102
MobiA	**0.0658**	**0.1177**	**0.0903**	**0.0862**

实验结果表明，MobiA 的轨迹合成效果显著优于 DeepMove，平均指标提升了约 80%。当移除自洽性提取机制或动机推理策略时，模型的性能分别下降了约 24%和 16%，这验证了出行模式提取在捕捉真实出行规律、推理策略模块在利用规律方面的协同作用。相较而言，改变群体出行模式的提取方式会更大程度的降低模型精度，证明了细粒度群体划分对于精确、个性化轨迹合成的重要性。如表 7 所示，本文进一步对细分人群属性“年龄、收入状况和职业”维度进行了消融实验。结果表明，年龄对出行模式的影响最为显著，其主导作用可能源于不同年龄段群体在出行频率、时段分布等特征上的显著差异，而职业的影响最低，可能与当前职业分类体系未能直接关联到出行行为差异有关。

表 7 多尺度用户属性下的模型表现评估

Table 7 Performance Comparison on Multiscale User Attributes

细分属性程度	SD↓	SI↓	ST-LOC↓	DailyLoc↓
年龄+收入状况+职业	**0.1022**	**0.0673**	**0.0918**	**0.0898**
年龄+收入状况	0.1254	0.0819	0.0934	0.0913
年龄+职业	0.2178	0.0902	0.1103	0.1455
收入状况+职业	0.1643	0.1561	0.1276	0.1637

为验证所提取的细粒度人群出行模式的有效性，并探究个体属性如何影响其在时空维度上的出行选择，本研究将该框架下智能体生成的一日行程轨迹与简单人群属性划分的生成结果进行了对比分析，通过两组对照实验进行论证。**（1）模拟居住在特定区域的 200 名 30-35 岁女性工作日 8:00-9:00 的出行**。实验结果如图 6 所示，图 6-（a）为无细分人群出行模式参考下智能体生成的出行情况，热点主要分布在商业办公区域区，仅简单模拟出了工作日的通勤动机。相比之下，图 6-（b）中学校附近的热点显著增加，这意味着智能体通过对于出行模式的学习，了解到中年女性往往兼顾着家庭和工作的责任，早上通常有送小孩上学的安排。

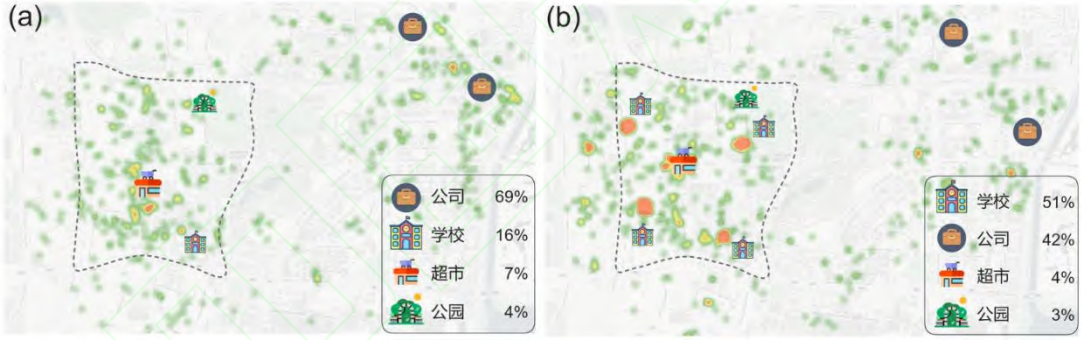


图 6 模拟 30-35 岁女性工作日 8:00-9:00 的出行目的地分布图

Fig. 6 Distribution Map of Weekday 8:00–9:00 am Travel Destinations among 30–35-year-old Women

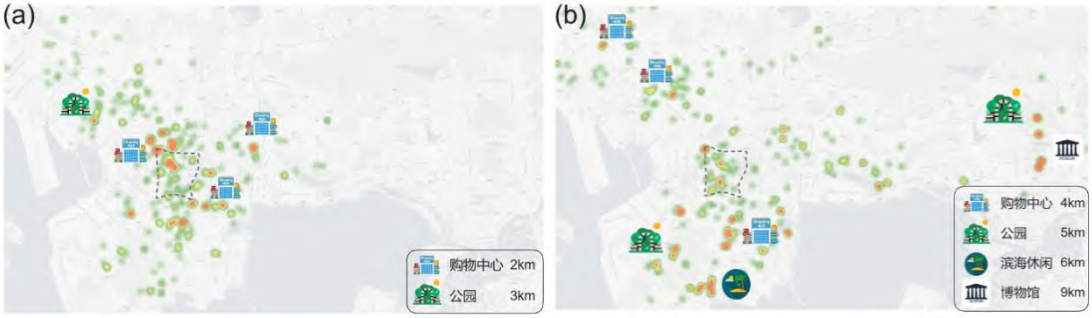


图 7 模拟 30-35 岁有车男性周末出行目的地分布图

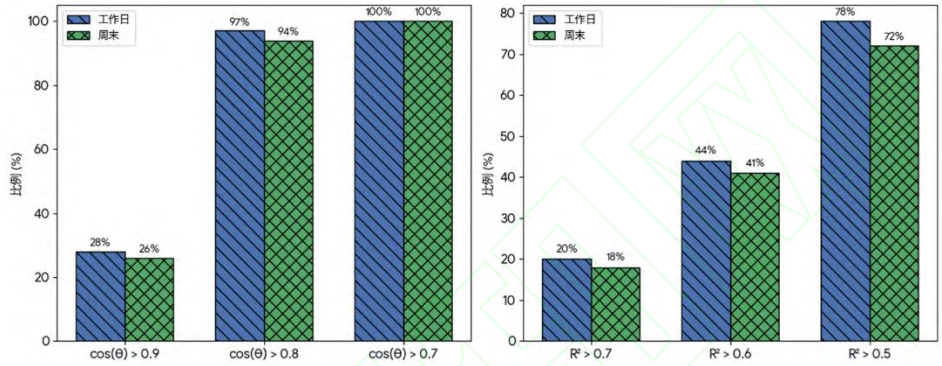
Fig. 7 Distribution of Weekend Travel Destinations among 30–35-year-old Male Car Owners

（2）**模拟居住在特定区域的 200 名 30-35 岁有车男性周末出行**。实验结果如图 7 所示，图 7-（a）

为无细分人群出行模式参考时智能体生成的出行分布，其活动半径多局限于居住区周边，符合就近休闲的普遍规律。相比之下图 7-（b）中周末中长距离出行比例显著增加，高频目的地包括大型购物中心、自然公园、滨海休闲区及博物馆。多元化的空间分布特征表明，智能体通过学习细分人群出行模式，能够准确掌握有车人群在私家车便利性的驱动下，更倾向于规划中长距离周末出行的行为特征。

2.2 轨迹生成结果与评估

本研究在大范围空间尺度上对生成结果与真实情况进行了宏观验证。基于实验区域真实的人口数量及属性画像，按照 1:10 的比例，模拟了约 5 万人的出行，并计算各地块 24 小时的动态人口数量，将其与百度地图 24 小时真实人口数据进行比对。

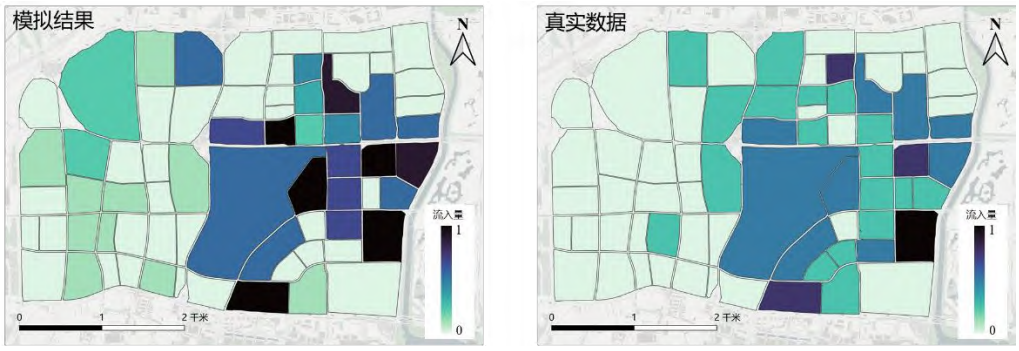


(a) 基于合成轨迹的 24 小时动态人口分布余弦相似度得分　　(b) 基于合成轨迹的地块内人口密度拟合情况

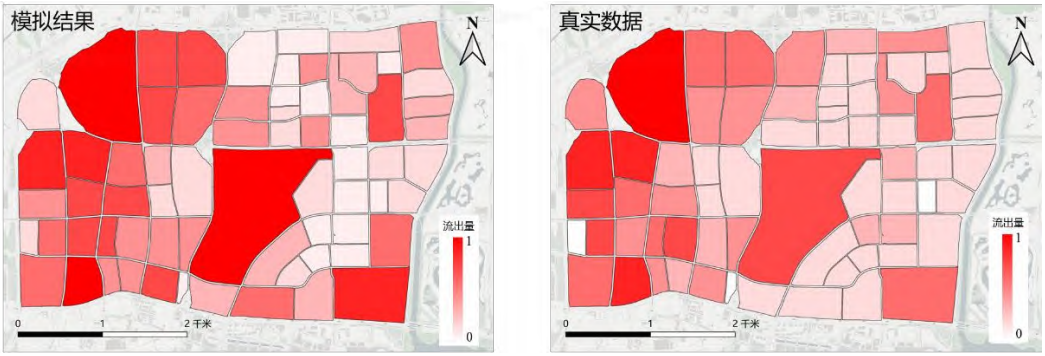
图 8 合成轨迹的时空评估

Fig. 8 Evaluating Generated Trajectories over Space and Time Scale

图 8-(a) 展示了基于合成轨迹的动态人口分布与真实数据分布的余弦相似度。结果显示，无论是在工作日或周末，指标得分大于 0.8 的地块占比达 90%以上。证明本文所提出的融合城市感知的轨迹生成策略能够准确建立从智能体的出行文本日志到现实地理空间的准确映射，在时空维度均展现出与真实数据的一致匹配。此外，如图 8-（b）所示，合成轨迹在超过 70%的地块上与真实人口密度的拟合性 R^2大于 0.5，证明了 MobiA 能够建立空间属性与人类出行的内部关联，并根据空间单元的语义属性推理、生成与其空间承载力相符的移动出行。图 9 从聚合的统计层面对比了工作日早高峰时段（7:00-9:00 AM）地块级别的人口流入和流出情况。MobiA 合成的出行日志成功捕捉了真实数据中人口高流入区域与低流入区域的空间格局，验证了模型在模拟宏观人流动态上的保真度。



(a) 工作日 7:00-9:00 AM 人口流入情况对比



(b) 工作日 7:00-9:00 AM 人口流出情况对比

图 9 工作日 7:00-9:00 AM 基于合成出行日志与真实数据的地块流入、流出人口对比

Fig. 9 Comparison of Population Inflow and Outflow in Parcels: Generated Travel Diaries vs. Real Data (7:00 - 9:00 AM on Working Day)

进一步，实验针对出行目的维度，检验模型对不同年龄段人口出行特征的捕捉能力。如表 8 所示，MobiA 能够合成全年龄段人群高度逼真的出行目的分布，与真实数据的余弦相似度达到约 0.98，平均 Hellinger 距离小于 0.16。为直观呈现模型对各年龄段出行目的分布的预测效果，实际分布与预测分布的雷达图对比如图 10 所示，所有年龄段核心出行目的的预测边界与真实分布趋势相吻合，高频出行目的的识别能力表现突出，同时也能够有效捕捉低频出行目的，模拟不同年龄段人群存在的差异化出行目的。

表 8 分年龄段出行目的拟合度评估

Table 8 Performance Comparison on Multiscale Age-Groups

年龄段	余弦相似度	Hellinger 距离
18 岁以下	0.985	0.144
18-25 岁	0.981	0.131
26-35 岁	0.981	0.148
36-45 岁	0.978	0.180
46-60 岁	0.984	0.170
60 岁以上	0.973	0.176

注：余弦相似度通过计算向量夹角的余弦值，聚焦于分布结构的相似性，反映不同年龄段出行目的占比的相对比例一致性，从趋势层面验证模型效果。Hellinger 距离则基于概率分布的平方根差异，量化两类分布的绝对差异，从统计距离层面刻画预测误差的大小。

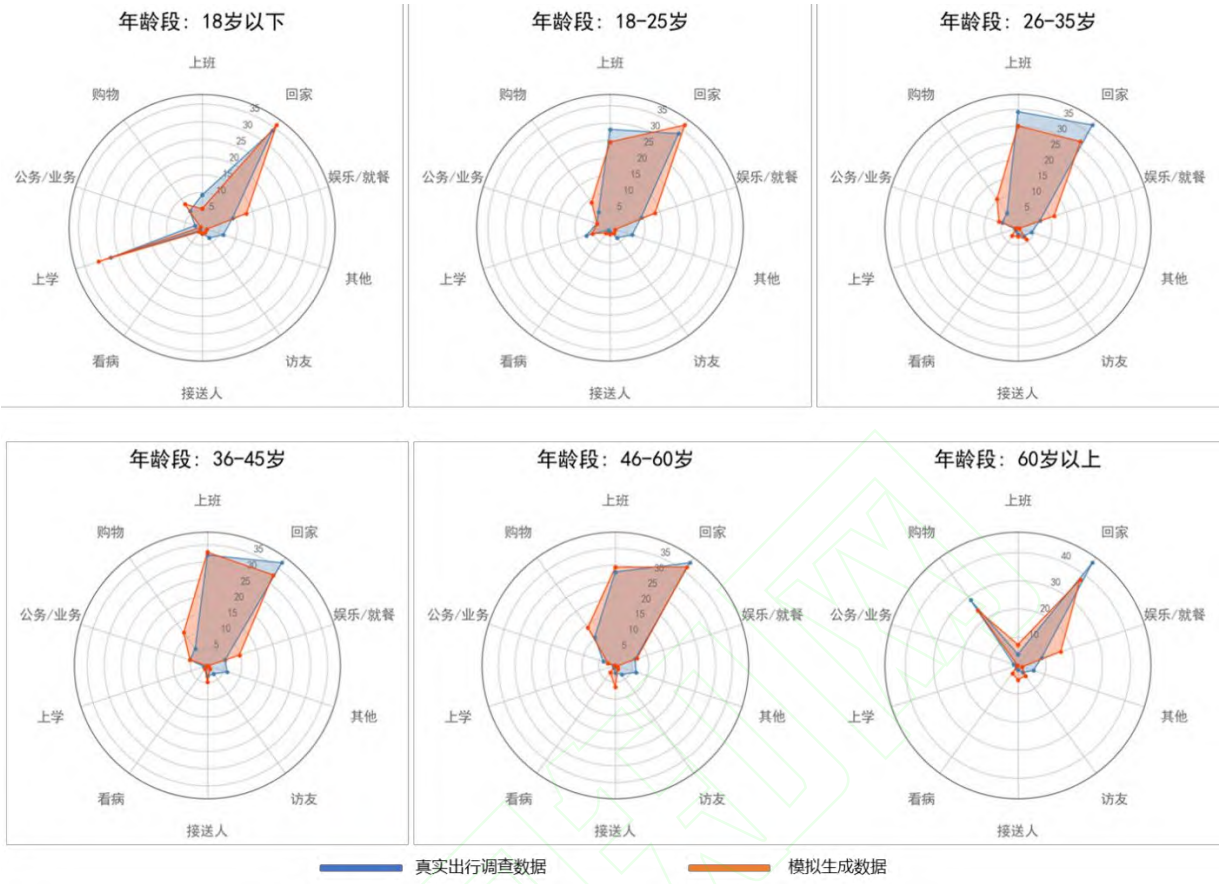


图 10 各年龄段出行目的分布对比雷达图

Fig. 10 Radar Chart Comparing the Distribution of Travel Purposes in Multiscale Age-Groups

3 结论与展望

本研究构建了基于 LLM-Agent 的城市出行日志生成框架 MobiA，提出属性-行为自洽与空间吸引力的双重约束机制。该框架通过注入结构化的出行关联知识，驱动 Agent 的决策过程同时符合两个层面的真实性：（1）作为“社会人”的决策，应遵循由其社会属性决定的具有差异化的行为规律；（2）作为“空间人”的行为，应遵循由城市物理环境功能所决定的空间选择约束。

MobiA 基于约 20 万条真实出行调查数据进行训练，实验结果验证了该框架的有效性。在属性-行为自洽的约束层面，基于多任务重建构建出社会属性与出行模式的关联知识库，并通过动机推理进行条件化生成，MobiA 因此能够精准捕捉人群出行行为的异质性与关联性，有效抑制合成过程中的“平均人[36]”效应。其次，基于地块吸引力模型的空间功能约束，成功将 Agent 的抽象出行意图准确映射至城市地理空间，保证了生成轨迹在人-地交互层面的高度真实性。MobiA 从人类出行的社会属性与空间吸引力的共同角度出发，为 LLM-Agent 在模拟城市出行任务上提供了一个兼具行为认知合理性与地理真实性的有效框架。由此生成的个性化出行日志，可作为以人地交互为核心的 GeoAI 模型与政策仿真系统的训练与验证数据，可用于交通仿真、人流预测、公共交通设施与地块功能评估等任务。

目前，MobiA 主要聚焦于单日出行链的建模，强调在多目的、多时间段和多地块选择的组合空间中刻画个体异质性的行为规律。对于跨周期的长程出行依赖建模、更微观的活动选择（如商圈内的具体 POI 位置），以及家庭成员或同事等多主体之间的交互机制，尚未展开系统性探讨。未来研究可在现

有框架基础上，引入长期记忆机制和多智能体交互模块，并结合 POI 粒度的空间映射与多尺度空间单元设计。进一步提升出行日志生成的精细度和现实适配性，并推动地理信息科学中的空间思维与生成式 AI 能力的深度融合，构建以“时空＋人本”为核心的可解释轨迹合成与空间大模型框架。

参考文献

[1] Tang S S, Zhang Y Q, Shan Z G, Wang W, Zhang Y Q. Current situation, trends and policy recommendations for the development of new smart cities in China[J]. E-Government, 2020(04): 70–80. (唐斯斯;张延强;单志广;王威;张雅琪; 我国新型智慧城市发展现状、形势与政策建议[J]. 电子政务, 2020(04): 70～80.)

[2] National Development and Reform Commission. Guiding opinions on deepening the development of smart cities and promoting city-wide digital transformation[R]. 2024[2025-09-01]. (关于深化智慧城市发展 推进城市全域数字化转型的指导意见[R]. 国家发展和改革委员会,2024[2025-09-01].)

[3] Batty M, Axhausen K W, Giannotti F, Pozdnoukhov A, Bazzani A, Wachowicz M, Ouzounis G, Portugali Y. Smart cities of the future[J]. The European Physical Journal Special Topics, 2012, 214(1): 481～518.

[4] YUE Y, Liu Y, Chen Y S, He L, Chen C, Li W W, Qin K, Jia T, Xu G, Wang F H, Wang J Y, Xie X, Xu F L, Xu Y, Su S L, Gui Z P, You L, Zhang M D, Zhang F, Zhang X X, Zhao B, Zhao Y L, Zhou Y L, Huang B, Cao K. Integration Path of Spatial and Geo-Computing and Computational Social Science[J]. Geomatics and Information Science of Wuhan University, 2022, 47(1): 1–18. (乐阳, 刘瑜, 陈云松, 贺力, 陈晨, 李文雯, 秦昆, 贾涛, 许刚, 王法辉, 王静远, 谢幸, 徐丰力, 徐阳, 苏世亮, 桂志鹏, 游兰, 张明达, 张丰, 张晓祥, 赵博, 赵耀龙, 周钰伦, 黄波, 曹凯. 空间和地理计算与计算社会学的融合路径[J]. 武汉大学学报（ 信息科学版), 2022, 47(1): 1～18.)

[5] Ouyang K, Shokri R, Rosenblum D, Yang W. A Non-Parametric Generative Model for Human Trajectories[C]. Twenty-Seventh International Joint Conference on Artificial Intelligence, 3812–3817 (2018). doi:10.24963/ijcai.2018/530

[6] Li R, Liu C H, Wu H Y. A Review of Urban Population Mobility Perception and Modeling Methods[J]. Geomatics and Information Science of Wuhan University, 2025, 50(05): 973–995. (李锐;刘朝辉;吴华意; 城市人口流动感知与建模方法综述[J]. 武汉大学学报(信息科学版), 2025(05 vo 50): 973～995.)

[7] Liu K. Approaches for human mobility data generation: Research progress and trends[J]. Journal of Geo-information Science, 2024,26: 1–17. (刘康. 人类移动数据生成方法：研究进展与趋势探讨[J]. 地球信息科学学报, 2024, 26: 1～17.)

[8] Fan C, Guo J L, Han X P, Wang B H. A review of human dynamics research[J]. Complex Systems and Complexity Science, 2011, 8(02): 1–17. (樊超;郭进利;韩筱璞;汪秉宏; 人类行为动力学研究综述[J]. 复杂系统与复杂性科学, 2011(02 vo 8): 1～17.)

[9] Liu Y, Kang C G, Wang F H. Towards Big Data-Driven Human Mobility Patterns and Models[J]. Geomatics and Information Science of Wuhan University, 2014, 39(06): 660–666. (刘瑜;康朝贵;王法辉; 大数据驱动的人类移动模式和模型研究[J]. 武汉大学学报(信息科学版), 2014(06 vo 39): 660～666.)

[10] Song C, Koren T, Wang P, Barabási A-L. Modelling the scaling properties of human mobility[J]. Nature Physics, 2010, 6(10): 818～823.

[11] Lu F, Liu K, Chen J. Research on Human Mobility in Big Data Era[J]. Journal of Geo-Information Science, 2014, 16(05): 665–672. (陆锋;刘康;陈洁; 大数据时代的人类移动性研究[J]. 地球信息科学学报, 2014(05 vo 16): 665～672.)

[12] Xiao S L, Fang Z X. Rethinking Human Behavior Research from the Perspective of Space-time GIS[J]. Geomatics and Information Science of Wuhan University, 2014, 39(06): 667–670. (萧世伦;方志祥; 从时空 GIS 视野来定量分析人类行为的思考[J]. 武汉大学学报(信息科学版), 2014(06 vo 39): 667～670.)

[13] Gonzâlez M C, Hidalgo C A, Barabási A-L. Understanding individual human mobility patterns[J]. Nature, 2008, 453(7196): 779～782.

[14] Long Q, Wang H, Li T, Huang L, Wang K, Wu Q, Li G, Liang Y, Yu L, Li Y. Practical Synthetic Human Trajectories Generation Based on Variational Point Processes[C]//Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York, NY, USA:Association for Computing Machinery,2023: 4561～4571[2023-09-10].

[15] Huang D, Song X, Fan Z, Jiang R, Shibasaki R, Zhang Y, Wang H, Kato Y. A Variational Autoencoder Based Generative Model of Urban Human Mobility[C]//2019 IEEE Conference on Multimedia Information Processing and Retrieval (MIPR).

[16] Jiang W, Zhao W X, Wang J, Jiang J. Continuous Trajectory Generation Based on Two-Stage GAN[A]. arXiv,2023[2023-02-12].

[17] Rao J, Gao S, Kang Y, Huang Q. LSTM-TrajGAN: A Deep Learning Approach to Trajectory Privacy Protection[C]. JANOWICZ K, VERSTEGEN J A. //11th International Conference on Geographic Information Science (GIScience 2021) - Part I. Dagstuhl, Germany: Schloss Dagstuhl–Leibniz-Zentrum für Informatik,2020: 12:1-12:17[2022-12-26].

[18] Rao J, Gao S, Zhu S. CATS: Conditional Adversarial Trajectory Synthesis for Privacy-Preserving Trajectory Data Publication Using Deep Learning Approaches[J]. International Journal of Geographical Information Science, 2023, 37(12): 2538～2574.

[19] Chu C, Zhang H, Wang P, Lu F. Simulating human mobility with a trajectory generation framework based on diffusion model[J]. International Journal of Geographical Information Science, 2024, 38(5): 1～32.

[20] Zhang Y, Yuan Y, Ding J, Yuan J, Li Y. Noise Matters: Diffusion Model-based Urban Mobility Generation with Collaborative Noise Priors[A]. arXiv,2025[2025-03-09].
[21] Zhu Y, Ye Y, Zhang S, Zhao X, Yu J J Q. DiffTraj: generating GPS trajectory with diffusion probabilistic model[C]. Proceedings of the 37th International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc.,2024: 65168～65188[2024-06-17].
[22] Wang J, Lin Y, Li Y. GTG: Generalizable Trajectory Generation Model for Urban Mobility[A]. arXiv,2025[2025-03-12].
[23] Liu K, Jin X, Cheng S, Gao S, Yin L, Lu F. Act2Loc: a synthetic trajectory generation method by combining machine learning and mechanistic models[J]. International Journal of Geographical Information Science, 2024, 38(3): 407～431.
[24] Park J S, O'Brien J C, Cai C J, Morris M R, Liang P, Bernstein M S. Generative Agents: Interactive Simulacra of Human Behavior[A]. arXiv,2023[2024-05-22].
[25] Zheng Y, Xu F, Lin Y, Santi P, Ratti C, Wang Q R, Li Y. Urban planning in the era of large language models[J]. Nature Computational Science, 2025: 1～10.
[26] Yan B, Li K, Xu M, Dong Y, Zhang Y, Ren Z, Cheng X. On protecting the data privacy of Large Language Models (LLMs) and LLM agents: A literature review[J]. High-Confidence Computing, 2025, 5(2): 100300.
[27] Wei J, Wang X, Schuurmans D, Bosma M, Ichter B, Xia F, Chi E H, Le Q V, Zhou D. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models[C].//Advances in Neural Information Processing Systems, [2025-09-01].
[28] Fu X, Li C, Quan S J, Yigitcanlar T, Wasserman D. Large language models in urban planning[J]. Nature Cities, 2025, 2(7): 585～592.
[29] Wang J, Jiang R, Yang C, Wu Z, Onizuka M, Shibasaki R, Xiao C. Large Language Models as Urban Residents: An LLM Agent Framework for Personal Mobility Generation[A]. arXiv,2024[2024-05-13].
[30] Shao C, Xu F, Fan B, Ding J, Yuan Y, Wang M, Li Y. Beyond Imitation: Generating Human Mobility from Context-aware Reasoning with Large Language Models[A]. arXiv,2024[2024-03-20].
[31] Piao J, Yan Y, Zhang J, Li N, Yan J, Lan X, Lu Z, Zheng Z, Wang J Y, Zhou D, Gao C, Xu F, Zhang F, Rong K, Su J, Li Y. AgentSociety: Large-Scale Simulation of LLM-Driven Generative Agents Advances Understanding of Human Behaviors and Society[A]. arXiv,2025[2025-09-01].
[32] Li N, Gao C, Li M, Li Y, Liao Q. EconAgent: Large Language Model-Empowered Agents for Simulating Macroeconomic Activities[A]. arXiv,2024[2024-05-25].
[33] Chen Z, Kelty S, Evsukoff A G, Welles B F, Bagrow J, Menezes R, Ghoshal G. Contrasting social and non-social sources of predictability in human mobility[J]. Nature Communications, 2022, 13(1): 1922.
[34] Cowley B R, Calhoun A J, Rangarajan N, Ireland E, Turner M H, Pillow J W, Murthy M. Mapping model units to visual neurons reveals population code for social behaviour[J]. Nature, 2024: 1～9.
[35] Huang L, Yu W, Ma W, Zhong W, Feng Z, Wang H, Chen Q, Peng W, Feng X, Qin B, Liu T. A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions[J]. ACM Trans. Inf. Syst., 2025, 43(2): 42:1-42:55.
[36] Igo S E. The averaged American: Surveys, citizens, and the making of a mass public[M]. Cambridge, MA, US: Harvard University Press,2007: ix, 398.
[37] Lewis P, Perez E, Piktus A, Petroni F, Karpukhin V, Goyal N, Küttler H, Lewis M, Yih W, Rocktäschel T, Riedel S, Kiela D. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Advances in Neural Information Processing Systems. Curran Associates, Inc.,2020: 9459～9474[2025-09-01].
[38] Cervero R, Kockelman K. Travel demand and the 3Ds: Density, diversity, and design[J]. Transportation Research Part D: Transport and Environment, 1997, 2(3): 199～219.
[39] Baran P K, Rodr ́guez D A, Khattak A J. Space Syntax and Walking in a New Urbanist and Suburban Neighbourhoods[J]. Journal of Urban Design, 2008[2025-07-31].
[40] Gao S. A Review of Recent Researches and Reflections on Geospatial Artificial Intelligence[J]. Geomatics and Information Science of Wuhan University, 2020, 45(12): 1865–1874. (高松. 地理空间人工智能的近期研究总结与思考[J]. 武汉大学学报(信息科学版), 2020, 45(12): 1865～1874.)
[41] Wang X, Wei J, Schuurmans D, Le Q V, Chi E H, Narang S, Chowdhery A, Zhou D. Self-Consistency Improves Chain of Thought Reasoning in Language Models[C]. [2025-09-01].
[42] Liu C, Sheng Y, Wei Z, Yang Y-Q. Research of Text Classification Based on Improved TF-IDF Algorithm[C]//2018 IEEE International Conference of Intelligent Robotic and Control Engineering (IRCE). [2025-09-17].
[43] Covington P, Adams J, Sargin E. Deep Neural Networks for YouTube Recommendations[C]//Proceedings of the 10th ACM Conference on Recommender Systems. New York, NY, USA: Association for Computing Machinery,2016: 191～198[2025-09-18].
[44] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization[A]. arXiv,2017[2025-09-19].
[45] Feng J, Li Y, Yang Z, Qiu Q, Jin D. Predicting Human Mobility with Semantic Motivation via Multi-task Attentional Recurrent Networks[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, PP(99).